Álgebra Linear aplicada à análise de crédito

O principal tópico abordado nesse trabalho é a utilização de regressão logística para classificação de credores, classificando-os como bons ou mals.

In [1]:

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns
%matplotlib inline

from collections import OrderedDict

# Bibliotecas de treinamento
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, precision_score, recall_score, confusion_ma
from sklearn.preprocessing import RobustScaler

# PCA
from sklearn.decomposition import PCA
```

In [2]:

```
default = pd.read_csv("UCI_Credit_Card.csv",index_col="ID")
pd.set_option('display.max_columns', None)
default['EDUCATION']=np.where(default['EDUCATION'] == 5, 4, default['EDUCATION'])
default['EDUCATION']=np.where(default['EDUCATION'] == 6, 4, default['EDUCATION'])
default['EDUCATION']=np.where(default['EDUCATION'] == 0, 4, default['EDUCATION'])
default['MARRIAGE']=np.where(default['MARRIAGE'] == 0, 3, default['MARRIAGE'])
default.rename(columns = {'default.payment.next.month': "default"}, inplace = True)
default.rename(columns = lambda x: x.lower(), inplace = True)
default.head()

```

Out[2]:

ID	limit_bal	sex	education	marriage	age	pay_0	pay_2	pay_3	pay_4	pay_5	pay_6	bill_
1	20000.0	2	2	1	24	2	2	-1	-1	-2	-2	3
2	120000.0	2	2	2	26	-1	2	0	0	0	2	2
3	90000.0	2	2	2	34	0	0	0	0	0	0	29
4	50000.0	2	2	1	37	0	0	0	0	0	0	46
5	50000.0	1	2	1	57	-1	0	-1	0	0	0	8

Descrição dos Dados(Features)

- **limit_bal**: Limite de crédito considerando o limite individual e familiar.
- **sex**: Gênero

    - 1 = Homem
    - 2 = Mulher
- **education**: Nível de escolaridade
    - 1 = Pós-Graduação
    - 2 = Universidade
    - 3 = Ensino Médio
    - 4 = Outros
- **marriage**: Estado Civil
    - 1 = Casado(a)
    - 2 = Solteiro(a)
    - 3 = Outros
- **age**: Idade(Anos)
- **pay_0** até **pay_6**: Histórico de pagamentos entre os meses de Abril e Setembro de 2005.
    - Números Negativos = Pagou Adiantado
    - 0 = Pagou na data correta
    - 1 = Com um mês de atraso
    - 2 = Com dois meses de atraso, ...

- **bill_amt1** até **bill_amt6**: Dívida acumulada nos meses de Abril e Setembro de 2005.
- **pay_amt1** até **pay_amt6**: Montante pago em antecipado
- **default**:
    - 1 = Não pagou
    - 0 = Pagou

Entendendo melhor os dados

In [3]:

```
sim = default.default.sum()
nao = len(default)-sim

sim_perc = round(sim/len(default)*100, 1)
nao_perc = round(nao/len(default)*100, 1)
import sys
plt.figure(figsize=(7,4))
sns.set_context('notebook', font_scale=1.2)
sns.countplot('default',data=default, palette="Blues")
plt.annotate('bom credor: {}'.format(nao), xy=(-0.3, 15000), xytext=(-0.3, 3000), size=
plt.annotate('mal pagador: {}'.format(sim), xy=(0.7, 15000), xytext=(0.7, 3000), size=1
plt.annotate(str(nao_perc)+" %", xy=(-0.3, 15000), xytext=(-0.1, 8000), size=12)
plt.annotate(str(sim_perc)+" %", xy=(0.7, 15000), xytext=(0.9, 8000), size=12)
plt.title('Contagem dos Cartões de Crédito', size=18)

plt.box(False);
```

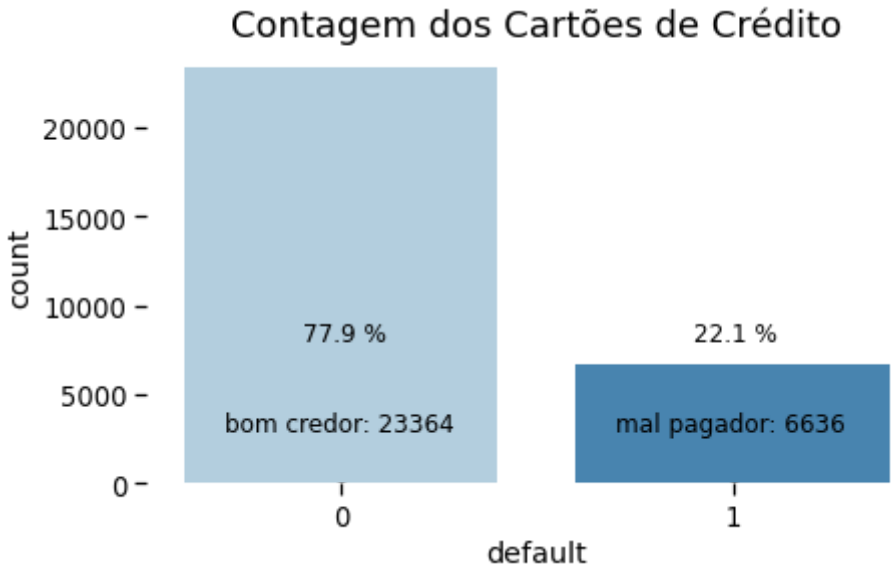

Algumas renderizações dos dados.

In [4]:

```
# Creating a new dataframe with categorical variables
subset = default[['sex','education','marriage','pay_0', 'pay_2', 'pay_3', 'pay_4', 'pay

f, axes = plt.subplots(3, 3, figsize=(20, 15), facecolor='white')
f.suptitle(' Frequência das Variáveis Categóricas')
ax1 = sns.countplot(x="sex", hue="default", data=subset, palette="winter", ax=axes[0,0]
ax2 = sns.countplot(x="education", hue="default", data=subset, palette="hot",ax=axes[0,
ax3 = sns.countplot(x="marriage", hue="default", data=subset, palette="spring",ax=axes[
ax4 = sns.countplot(x="pay_0", hue="default", data=subset, palette="binary", ax=axes[1,
ax5 = sns.countplot(x="pay_2", hue="default", data=subset, palette="summer", ax=axes[1,
ax6 = sns.countplot(x="pay_3", hue="default", data=subset, palette="cool", ax=axes[1,2]
ax7 = sns.countplot(x="pay_4", hue="default", data=subset, palette="autumn", ax=axes[2,
ax8 = sns.countplot(x="pay_5", hue="default", data=subset, palette="rainbow", ax=axes[2
ax9 = sns.countplot(x="pay_6", hue="default", data=subset, palette="icefire", ax=axes[2
```

Frequência das Variáveis Categóricas

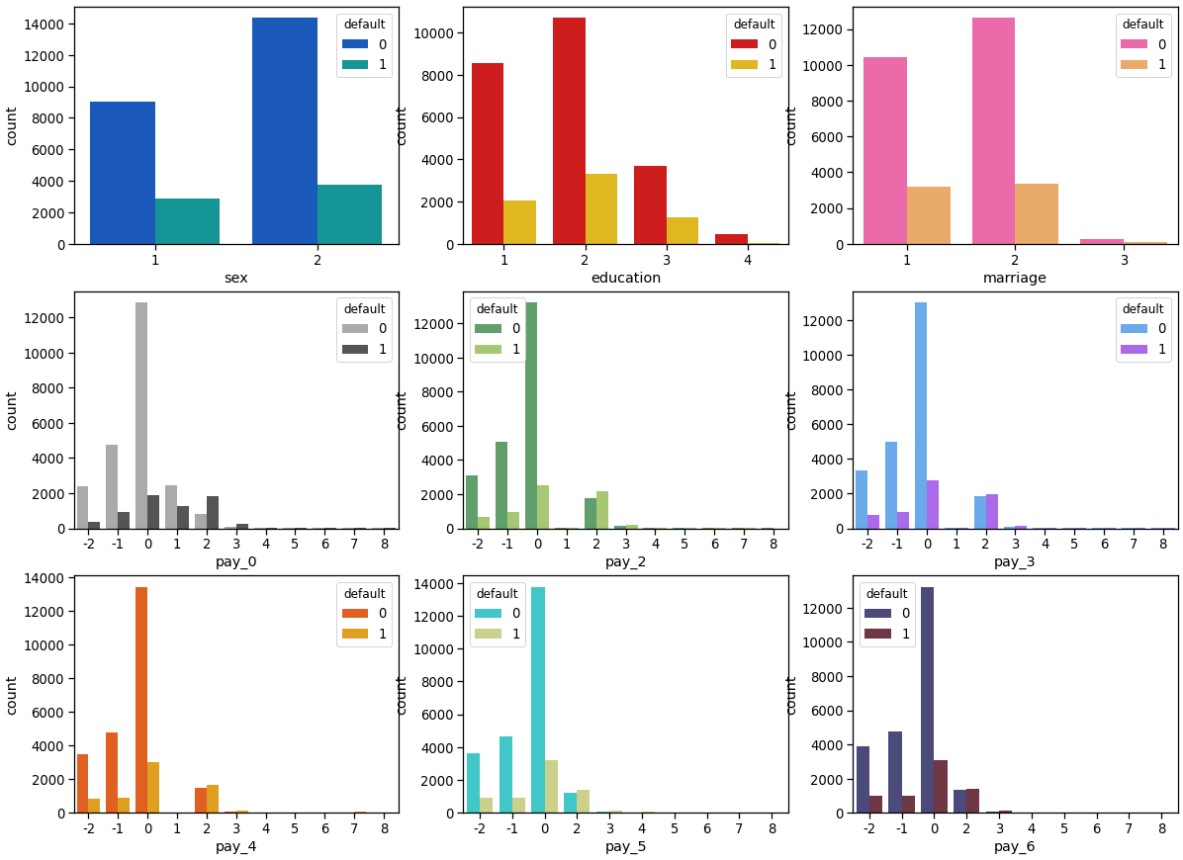

A partir da análise visual, é notável que mulheres(2), graduados(2), solteiros(2) e todos os que costumam pagar na data prevista tendem a ser bons credores.

Preparação dos dados

Antes de realizar qualquer operação com os dados, é preciso que as informações estejam formatadas adequadamente. Diante disso, faz-se necessário dispor os dados qualitativos no formato binário, fazendo alterações semelhantes ao do exemplo abaixo:

Tabela exemplo:

Sex:
Male
Female

Tabela exemplo no formato binário:

id	**Male**	**Female**
1	1	0
2	1	0
3	0	1

Os dados da segunda tabela, nessa formatação, são denominados dummy features

In [5]:

```
#Formatando os dados
default['grad_school'] = (default['education']==1).astype('int')
default['university'] = (default['education']==2).astype('int')
default['high_school'] = (default['education']==3).astype('int')
default.drop('education', axis=1, inplace=True)

default['male'] = (default['sex']==1).astype('int')
default.drop('sex', axis=1,inplace=True)

default['married'] = (default['marriage'] == 1).astype('int')
default.drop('marriage', axis=1, inplace=True)
default.sample(2)
```

Out[5]:

ID	limit_bal	age	pay_0	pay_2	pay_3	pay_4	pay_5	pay_6	bill_amt1	bill_amt2	bill_am
6972	20000.0	37	0	0	-2	-1	0	0	15960.0	0.0	-195
14075	90000.0	28	1	2	2	2	2	0	56889.0	55407.0	6442

Os indivíduos que antecipam os pagamentos ou pagam na data prevista são bons credores. Diante disso, é útil resumi-los a variável 0 nas colunas pay_0 a pay_6, uma vez que, a predição ficará menos complexa.

In [6]:

```
pay_features = ['pay_0', 'pay_2','pay_3','pay_4','pay_5','pay_6']

#Substituindo todos os valores negativos por 0
for p in pay_features:
    default.loc[default[p]<=0,p] = 0

```

Regressão Linear

Vamos observar um exemplo com Regressão Linear e o porquê ela não é ideal para esse tipo de análise.

In [7]:

```
sns.lmplot(x='limit_bal', y= 'bill_amt2', data = default, hue ='default',
           palette='coolwarm', height=7)
plt.title('Regressão Linear: Distinguindo pagadores e não pagadores\n\n', size=18)

sns.lmplot(x='bill_amt1', y= 'bill_amt2', data = default, hue ='default',
           palette='coolwarm',height=7)
plt.title('Regressão Linear:\n Não pode distinguir entre pagadores e não pagadores\n',

```

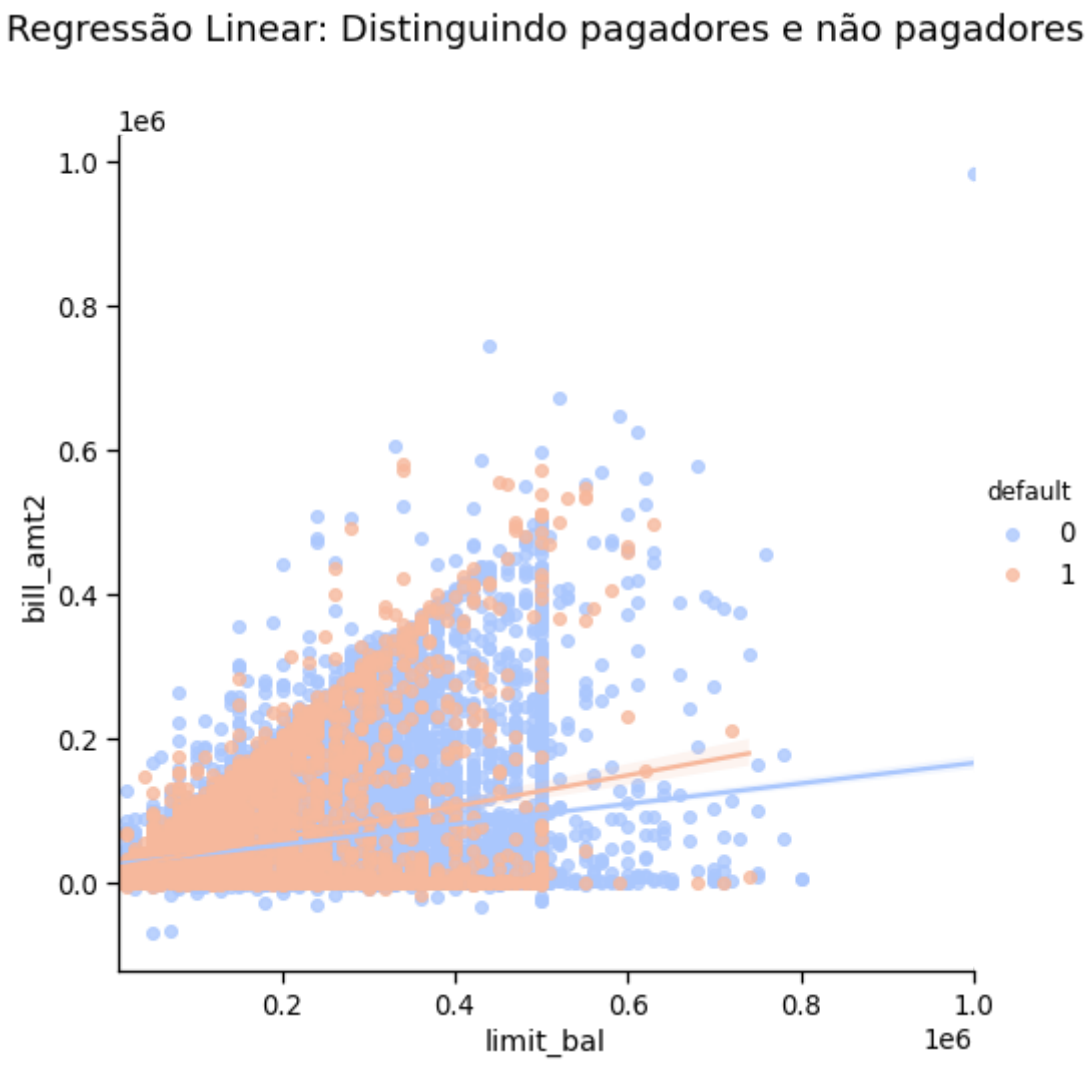

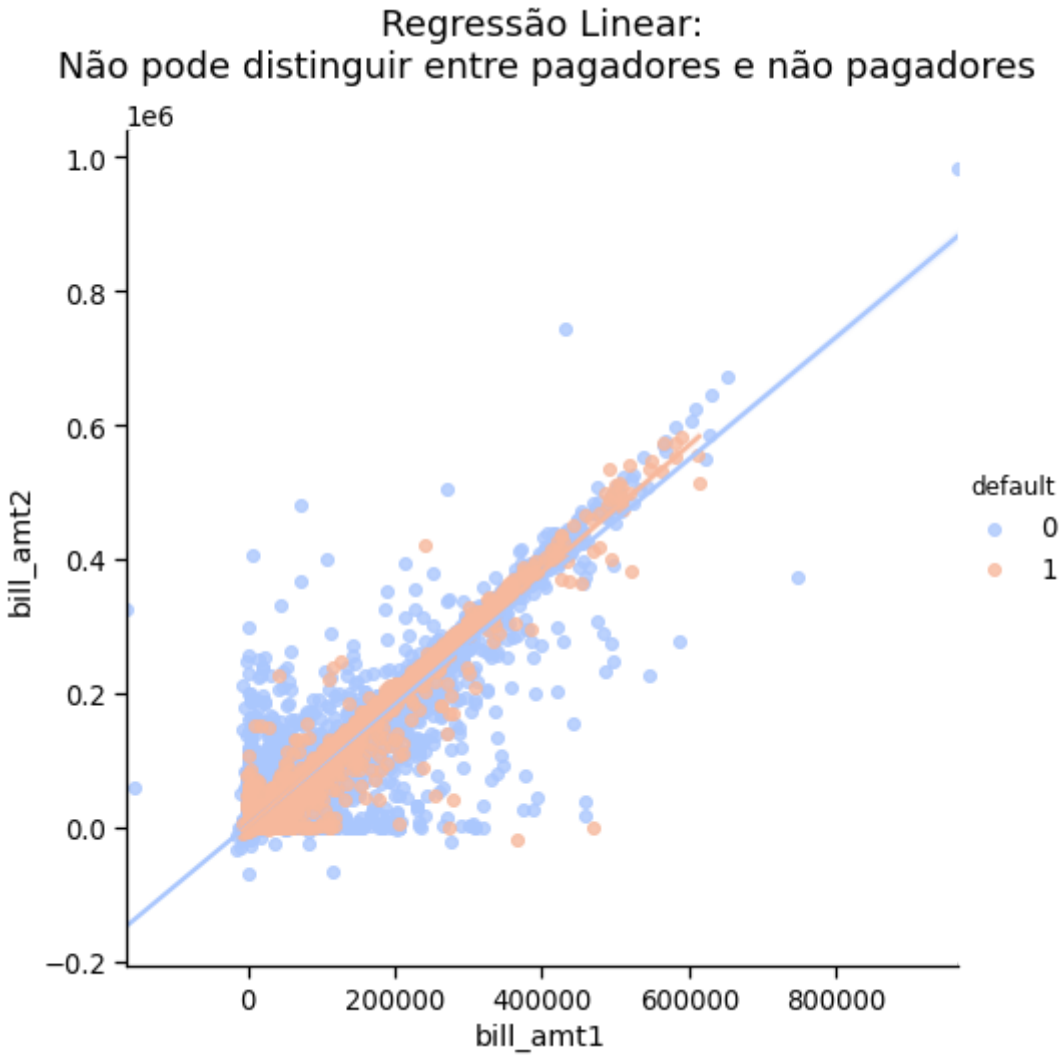

Regressão Linear prediz com mais precisão modelos em que a saída é um valor contínuo, enquanto que, Regressão Logística modela melhor casos em que é necessário uma resposta binária como True or False.

Regressão Logística

A Regressão Logística é uma técnica estatística cujo o objetivo é predizer a ocorrência de um evento dado um cojunto de dados.

Nesse notebook, a Regressão Logística será usada para avaliar se um indivíduo é um bom credor, baseado em seus dados pessoais.

Criando o Primeiro Modelo usando todos os dados

In [8]:

```
#Bibliotecas úteis do sklearn
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score, precision_score, recall_score, confusion_ma
from sklearn.preprocessing import RobustScaler
```

Como a Regressão Logística é um modelo de Machine Learning supervisionado, é preciso separar do DataFrame as labels e os dados. Dessa forma, o modelo modificará os parâmetros de uma função para que as informações inseridas, de cada usuário, nessa função, resultem nos valores 0 ou 1. De modo que, esses valores binários corresponderão a classificação 0 (bom credor) ou 1 (mal pagador).

$$f : R^n \rightarrow k \in [0, 1]$$

In [9]:

```
#Armazenando as labels
y = default.copy()['default']
#Armazenando os dados
X = default.copy().drop('default', axis=1)
```

Normalizando os dados

Em tese, Regressão Logística não precisa de normalização de Dados, pois esta trabalha com probabilidades(veremos sobre isso adiante), porém a existência de outliers podem prejudicar a performance do modelo. Nesse sentido, a normalização faz-se necessária antes de implementar o modelo e para este fim, a função `RobustScaler` , do `SKLEARN` , é ideal, pois remove os valores que não estão entre o 1º e 2º quartil e normaliza os dados.

In [10]:

```
#Removendo os outliers
robust_scaler = RobustScaler()
X = robust_scaler.fit_transform(X)
X = pd.DataFrame(X, columns = default.drop("default", axis = 1).columns)
```

Em seguida, é necessário extrair alguns dados e labels de test, para que ao fim da modelagem sejam usados na avaliação da performance do modelo.

In [11]:

```
#Separando os dados de treino e test
X_train, X_test, y_train, y_test = train_test_split(X,y, test_size=0.15, random_state =
```

Após o tratamento dos dados, aparentemente, já é viável executar o modelo. Mas antes, vale entender a Matemática que compõe o modelo de Regressão Logística.

A Matemática da Regressão Logística

Como dito anteriormente, este é um método de aprendizado supervisionado, ou seja, o modelo realiza a tarefa de aprender uma função que mapeia uma entrada para obter uma saída, com base em pares de entrada-saída.

O termo Logística deriva do termo log odds, no qual, odds refere-se a razão entre a probabilidade de um evento acontecer e a probabilidade de não acontecer. O modelo recebeu este nome devido a utlização de log odds no cálculo da Regressão.

$$Odds = \frac{P(event)}{1 - P(event)}$$

O gráfico da Regressão Logística é gerado a partir de uma função Sigmoide e uma das razões para usar essa curva é por se adequar melhor a modelos de classificação binária, uma vez que, os valores de saída podem ser interpretados como a probabilidade de um evento acontecer, já que estes variam entre 0 e 1.

$$p(X) = \frac{1}{1 + e^{-BX}}; p(x) \in [0, 1]; X, B \in R^n$$

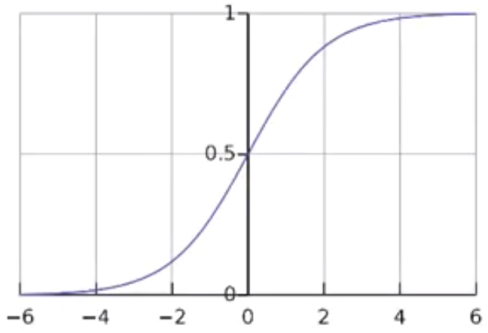

A Regressão Logística estimará o parâmetro B de modo que função Sigmoide atinja a maior similaridade.

Estimando o parâmetro

- Suponha que exista N amostras com labels 0 ou 1.
- Algumas amostras correspondem as Labels "1".
- Já outras amostras correspondem as Labels "0"
- O objetivo é estimar um B tal que, p(x) esteja o mais próximo de 1 nas amostras "1" e (1-p(x)) o mais próximo de 1 nas amostras "0"

$$\prod_{s\ em\ yi=1} p(x_i) = p(x_1) * p(x_2) * \ldots * p(x_n)$$

$$\prod_{s\ em\ yi=0} 1 - p(x_i) = (1 - p(x_1)) * (1 - p(x_2)) * \ldots * (1 - p(x_n))$$

$$L(B) = \prod_{s\ em\ yi=1} p(x_i) * \prod_{s\ em\ yi=0} (1 - p(x_i))$$

$$L(B) = \prod_{s} p(x_i)^{yi} * (1 - p(x_i))^{1-y_i}$$

Aplicando log odds para isolar o parâmetro BX e transformar o produtório em somatório

$$log(L(B)) = log(\prod_{s} p(x_i)^{yi} * (1 - p(x_i))^{1-y_i}) = l(b)$$

$$l(B) = \sum_{i=1} y_i \log(\frac{1}{1 + e^{-Bx_i}}) + (1 - y_i) \log(1 - p(x_i))$$

$$l(B) = \sum_{i=1} y_i Bx_i + \log(\frac{1}{1 + e^{Bx_i}})$$

$$l(B) = \sum_{i=1} Bx_i - \log 1 + e^{Bx_i}$$

$$B = arg \max_{B} l(B)$$

$$

Como essa equação é transcendental, não existe um B exato, entretanto, o Método de Newton oferece uma boa apromixação para este valor.

$$B^{t+1} = B^t - \frac{\nabla_B l(B^t)}{\nabla_{BB} l(B^t)}$$

Calculando o gradiente $\nabla_B l$

$$\nabla_B l = \sum_{i=1} \nabla_B [y_i Bx_i] - \nabla_B [log(1 + e^{Bx_i})]$$

$$\nabla_B l = \sum_{i=1} y_i x_i - [\frac{1}{1 + e^{Bx_i}} e^{Bx_i} x_i]$$

$$\nabla_B l = \sum_{i=1} y_i x_i - [\frac{1}{1 + e^{-Bx_i}} x_i]$$

$$\nabla_B l = \sum_{i=1} [y_i - p(x_i)] x_i$$

Convertendo para a representação matricial

$$\nabla_B = X^T (Y - \hat{Y})$$

Calculando o gradiente ∇_{BB}, que é uma matrix de Hessian

$$\nabla_{BB} l = \sum_{i=1} \nabla_B [y_i - p(x_i)] x_i$$

$$\nabla_{BB} l = \sum_{i=1} \nabla_B - p(x_i) x_i$$

$$\nabla_{BB} l = \sum_{i=1} \nabla_B - [\frac{1}{1 + e^{-Bx_i}}] x_i$$

$$\nabla_{BB} l = \sum_{i=1} [\frac{1}{1 + e^{-Bx_i}}]^2 e^{-Bx_i} (-x_i) x_i$$

$$\nabla_{BB} l = - \sum_{i=1} [\frac{e^{-Bx_i}}{1 + e^{-Bx_i}}][\frac{1}{1 + e^{-Bx_i}}] x_i^T x_i$$

$$\nabla_{BB} l = - \sum_{i=1} p(x_i)(1 - p(x_i)) x_i^T x_i$$

Convertendo para forma matricial

$$\nabla_{BB} l = -X^T P(1-P)X$$
$$\nabla_{BB} l = -X^T W X$$

Desse modo, iterando a fórmula abaixo obtemos o parâmetro B.

$$B^{t+1} = B^t + (X^T W X)^{-1} X^T (Y - \hat{Y}^t)$$

Perspectiva Geométrica da Regressão Logística

Quando é aplicado ""log odds"" na Função Sigmoide, obtém-se a reta $BX \in \mathbb{R}^n$

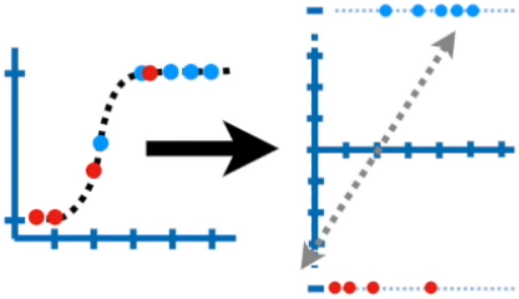

Ao calcular o vetor B com Método de Newton, geometricamente, a reta BX rotacionará até que os coeficientes de B convirjam em um vetor que torna a função Sigmoide o mais similar possível.

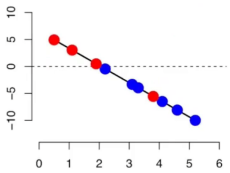

Implementando o modelo

In [12]:

```
# 1. Importando o modelo
from sklearn.linear_model import LogisticRegression

#2. Criando uma instância para estimar
logistic_regression = LogisticRegression(n_jobs=-1, random_state=15)

#3. Usando os dados de treino para treinar o modelo
logistic_regression.fit(X_train,y_train);
```

Avaliando o Modelo

In [13]:

```
def CMatrix(y_pred_test,y_true):
    from pandas import DataFrame
    CM = confusion_matrix(y_pred_test, y_test)
    df = pd.DataFrame(
        data={'Positive(Predicted)':CM[0,:],'Negative(Predicted)':CM[1,:]},
        index=['Positive','Negative'])
    return df

def model_metrics(X_test,y_test, logistic_regression):
    metrics = pd.DataFrame(index=['accuracy', 'precision', 'recall'],columns=['Logistic
    y_pred_test = logistic_regression.predict(X_test)
    print()
    metrics.loc['accuracy', 'LogisticReg'] = accuracy_score(y_pred=y_pred_test, y_true=
    metrics.loc['precision', 'LogisticReg'] = precision_score(y_pred=y_pred_test, y_tru
    metrics.loc['recall', 'LogisticReg'] = recall_score(y_pred=y_pred_test, y_true=y_te
    metrics['metric_type'] = metrics.index
    #print(metrics)
    #print(CMatrix(y_pred_test=y_pred_test, y_true=y_test))
    return metrics

metrics_model_1=model_metrics(X_test,y_test,logistic_regression)
```

Analisando os coeficientes da função

O vetor parâmetro B possui um coeficiente para cada feature e os valores absolutos desses coeficientes representam a importância de cada feature no modelo de predição. Abaixo, há um gráfico com todos os valores de B atrelado as features correspondentes.

In [14]:

```
logistic_regression.coef_[0]
default.columns
f,ax = plt.subplots(figsize=(8, 7))
coef_plot = sns.barplot(y=default.columns.drop('default'),x=abs(logistic_regression.coe
```

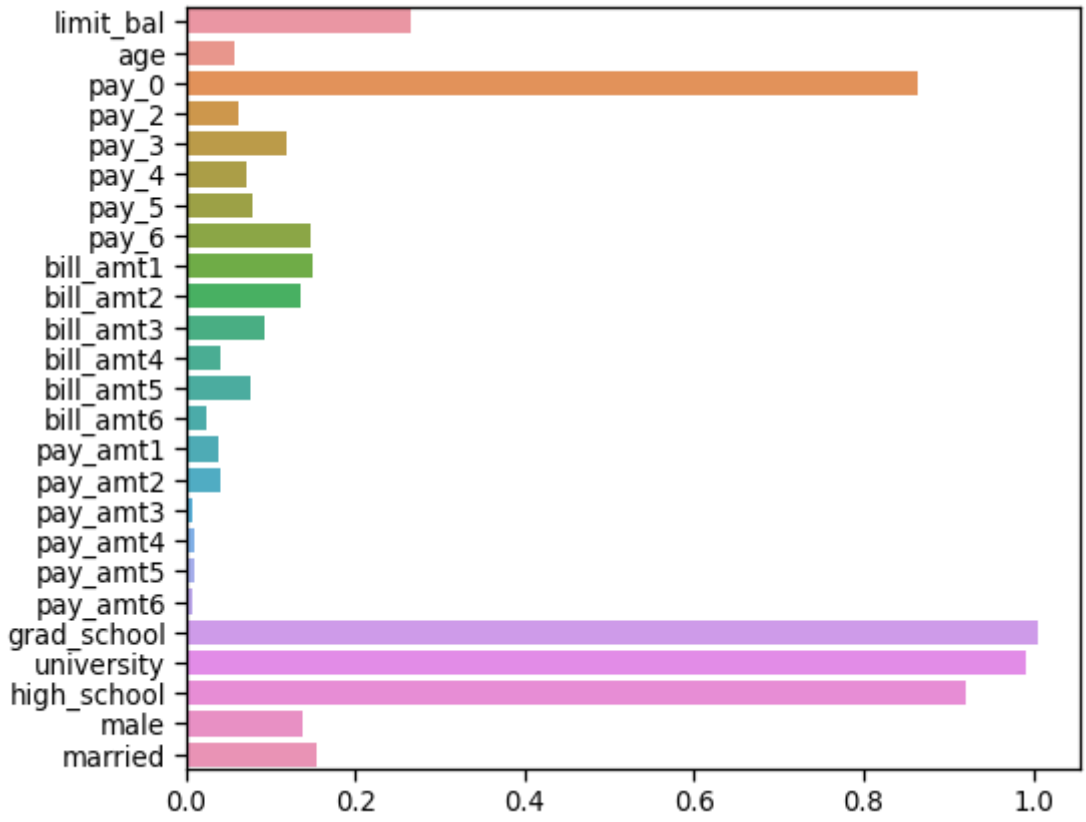

Ao observar o gráfico, fica visível que os dados de pay_amt1 a pay_amt6 oferecem pouca informação para o modelo.

Analisando a correlação entre as features

Outro fator importante a ser analisado é a correlação entre os dados, posto que, quando há grande correlação, os dados não oferecem tanta informação para o modelo. Diante disso, é válido observar o heatmap que demonstra a correlação entre as features utilizadas.

In [15]:

```
corr = default.corr()
f,ax = plt.subplots(figsize=(8, 7))
sns.heatmap(corr, cbar = True,  square = True, annot = False, fmt= '.1f',
            xticklabels= True, yticklabels= True
            ,cmap="coolwarm", linewidths=.5, ax=ax)

plt.title('MATRIZ DE CORRELAÇÃO - HEATMAP', size=10)
```

Out[15]:

```
Text(0.5, 1.0, 'MATRIZ DE CORRELAÇÃO - HEATMAP')
```

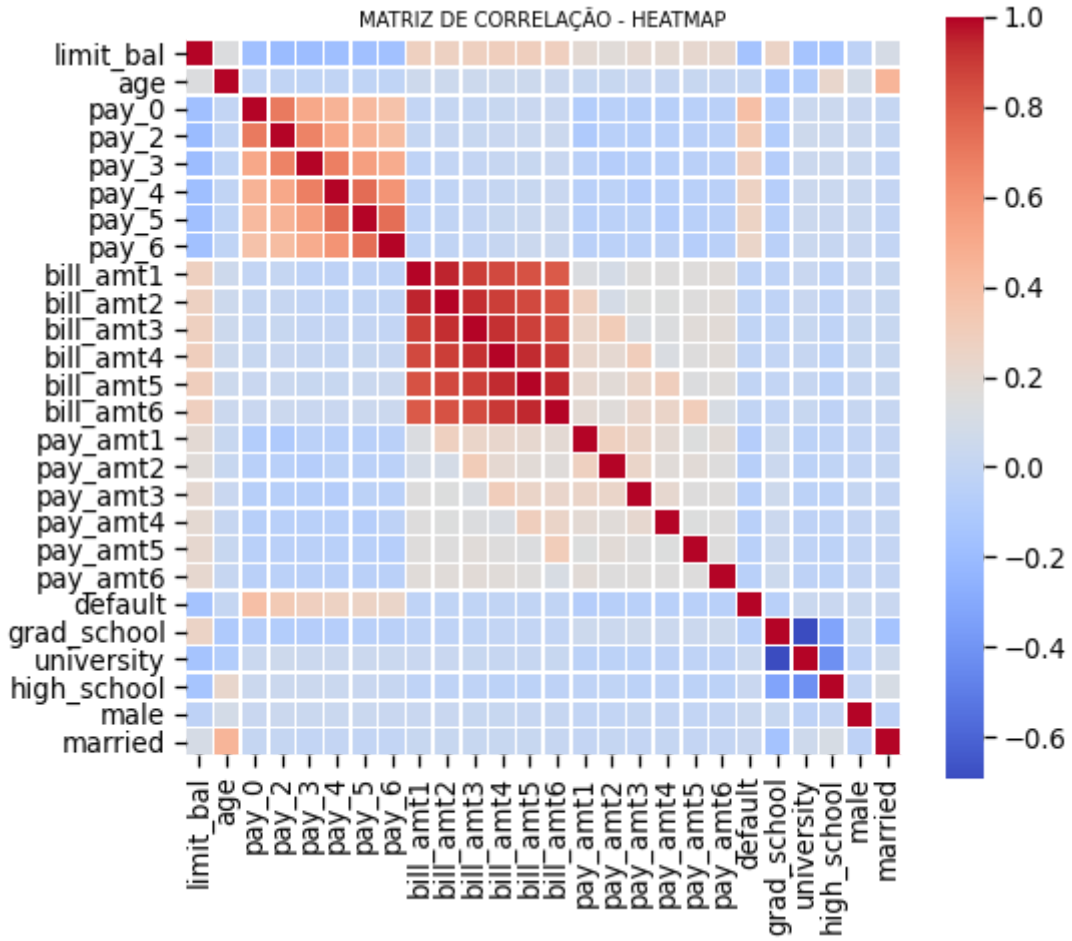

Com esse plot, fica visível a correlação entre os bill_amt. Dessa forma, é possível concluir que a bill_amt de

um mês é suficiente para o modelo, tendo em vista que as bill_amts de outros meses apenas repetem a mesma informação.

Após essa análise, conclui-se que é recomendável remover do modelo pay_amt1, pay_amt2,..., pay_amt6 e bill_amt1,bill_amt2,...,bill_amt5, visto que, acrescentam pouca informação ao modelo. Desse modo, pensando na implementação em larga escala, a remoção dessas 11 features pode diminuir bastante os custos de processamento, armazenamento e coleta de dados de uma empresa.

Re-implementando o modelo

Diante das alterações do conjunto, faz-se necessário re-implementar o modelo e avaliar as alterações nas métricas de predição.

In [16]:

```
#Removendo as features
default2 = default.copy().drop(['pay_amt1','pay_amt2','pay_amt3','pay_amt4','pay_amt5',
y_2 = default2['default']
X_2 = default2.copy().drop('default',axis=1)

#Removendo os outliers e normalizando
robust_scaler_2 = RobustScaler()
X_2 = robust_scaler_2.fit_transform(X_2)

#Separando os Dados
X_train_2, X_test_2, y_train_2, y_test_2 = train_test_split(X_2,y_2, test_size=0.15, ra

#Reimplementado o modelo
logistic_regression_2 = LogisticRegression(n_jobs=-1, random_state=15)

logistic_regression_2.fit(X_train_2,y_train_2)

metrics_model_2 = model_metrics(X_test_2,y_test_2,logistic_regression_2)

```

Comparando resultados

Com os resultados da nova implementação, é possível concluir que, realmente, os dados removidos eram irrelevantes. O gráfico demonstra a precisão, acurácia e recall das duas implementações

In [17]:

```
metrics_model_2['model'] = 'model_2'
metrics_model_1['model'] = 'model_1'
g = sns.catplot(data=pd.concat([metrics_model_1,metrics_model_2]), kind='bar', y='Logis
```

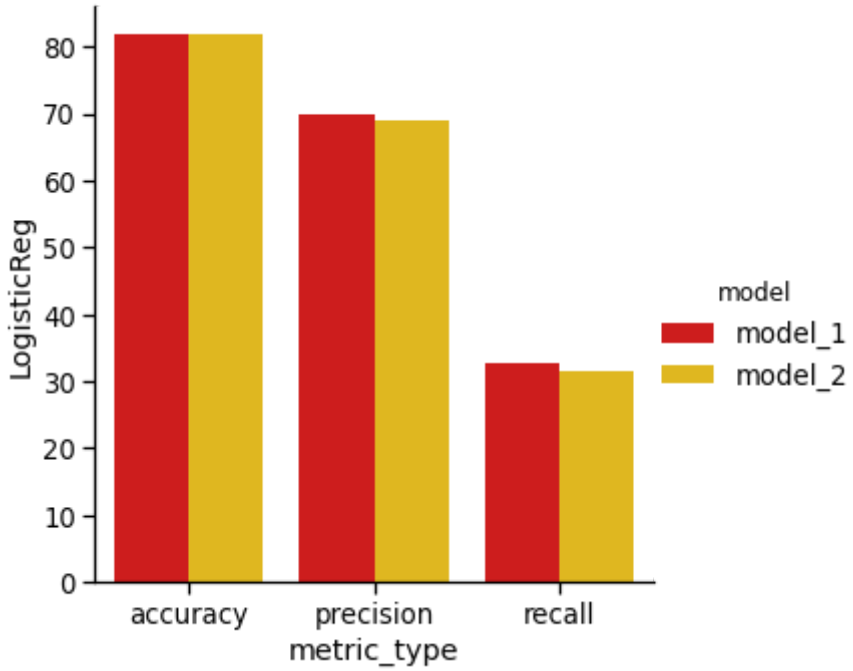

Utilizando PCA

O Principal Component Analysys (PCA), é uma operação linear que utiliza Singular Value Decomposition(SVD) para reduzir um conjunto de features possivelmente correlacionadas num conjunto de valores de variáveis linearmente não correlacionadas chamadas de componentes principais.

Matemática do PCA(exemplo explicativo)

Seja o conjunto de dados representado por X. No cálculo do PCA, primeiramente, obtem-se a média dos n valores de cada coluna de X.

$$\frac{\sum_j X_{ji}}{n}$$

Agora, é necessário determinar a matriz de coavariancia, para tal, considere uma matriz auxiliar M obtida da seguinte forma:

$$M = X - \frac{\sum_j X_{ji}}{n}$$

Logo, a matriz de covariância C é:

$$C = \frac{M^T M}{n-1}$$

Diante disso, é preciso calcular os auto-valores e auto-vetores da matriz C. Os auto-valores λ de C são raízes do seguinte polinômio característico:

$$p_C(Y) = det(C - YI)$$

E os auto-vetores q pertencem ao conjunto:

$$(C - \lambda I)q = 0$$

Faz-se necessário calcular o quanto cada auto-vetor(componentes) representa na taxa de variação dos dados, para isso vamos analisar a variância de cada auto-valor:

$$var(\lambda) = \frac{\lambda}{\sum_j \lambda_j}$$

Logo, com o conjunto das variâncias dos auto-valores pode-se determinar as componentes principais do dado conjunto. A importância de cada componente é dada pelo valor da variância do auto-valor correspondente.

Reduzindo o conjunto de dados às 13 principais componentes

In [18]:

```
from sklearn.decomposition import PCA
#Definindo a dimensão dos dados
pca = PCA(13)
#PCA no conjunto de treino
pca_X = pca.fit(X)

X_pca = pd.DataFrame(pca_X.transform(X))
X_pca.head()
```

Out[18]:

	0	1	2	3	4	5	6	7	
0	-3.339702	1.209778	-0.426773	0.309149	0.165696	-0.348627	1.198143	0.979059	-0.52719
1	-2.915311	0.797967	-0.547978	0.430450	0.294873	-0.554742	1.188430	0.905603	-0.86573
2	-2.246350	0.234234	-0.976335	0.378132	0.169322	-0.271923	0.824479	-0.652101	-0.42399
3	-2.267245	0.837629	-0.186583	0.242701	0.055321	-0.024043	-0.120276	-0.699375	0.12211
4	4.589981	5.525321	-0.296593	0.641106	1.701635	-2.372474	1.211485	-0.488318	1.48947

In [19]:

```
#Fazendo o split no conjunto reduzido
X_train_pca, X_test_pca, y_train, y_test = train_test_split(X_pca, y, test_size = 0.15,
```

In [20]:

```
from sklearn.linear_model import LogisticRegression

#2. Criando uma instância para estimar
logistic_regression_pca = LogisticRegression(n_jobs=-1, random_state=15)

#3. Usando os dados de treino para treinar o modelo
logistic_regression_pca.fit(X_train_pca,y_train);


```

In [21]:

```
metrics_model_pca = model_metrics(X_test_pca,y_test,logistic_regression_pca)
```

Nova correlação entre as veriáveis

In [22]:

```
corr = X_train_pca.corr()
f,ax = plt.subplots(figsize=(8, 7))
sns.heatmap(corr, cbar = True,  square = True, annot = False, fmt= '.1f',
            xticklabels= True, yticklabels= True
            ,cmap="coolwarm", linewidths=.5, ax=ax)
plt.title(f'MATRIZ DE CORRELAÇÃO APÓS PCA\n({len(X_test_pca.columns)} componentes) - HE
```

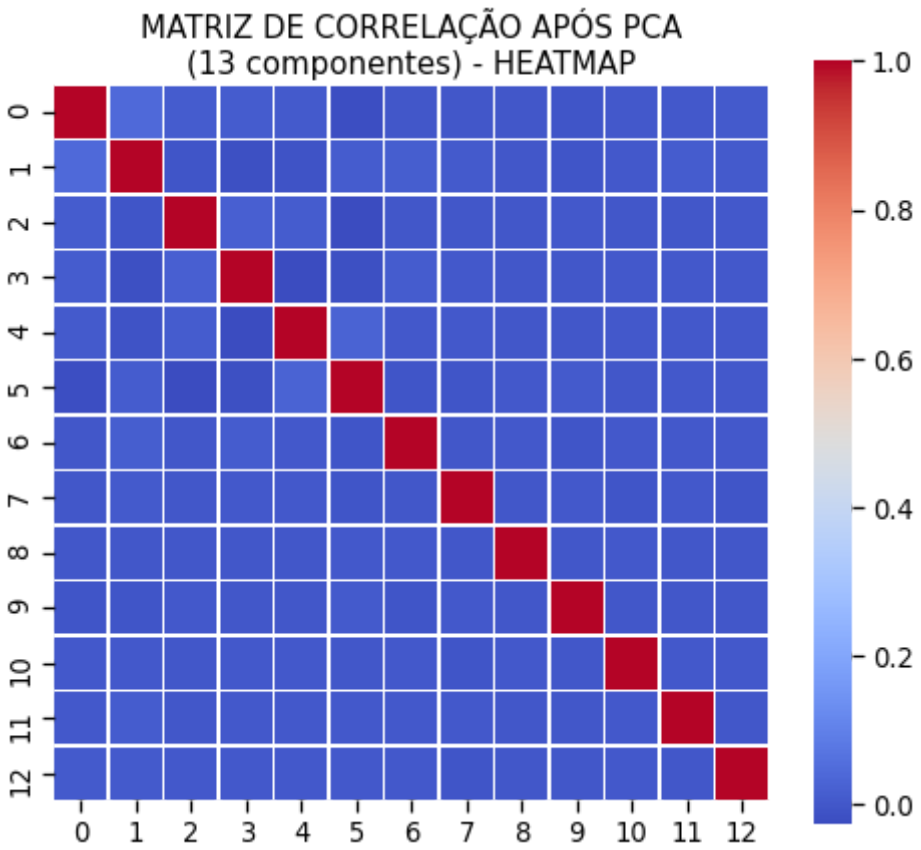

Reduzindo o conjunto de dados às 9 principais componentes

Apenas a título de comparação das métricas

In [23]:

```
#Definindo a dimensão dos dados
pca = PCA(9)
#PCA no conjunto de treino
pca_X = pca.fit(X)

X_pca = pd.DataFrame(pca_X.transform(X))

#Fazendo o split no conjunto reduzido
X_train_pca, X_test_pca, y_train, y_test = train_test_split(X_pca, y, test_size = 0.15,

#2. Criando uma instância para estimar
logistic_regression_pca = LogisticRegression(n_jobs=-1, random_state=15)

#3. Usando os dados de treino para treinar o modelo
logistic_regression_pca.fit(X_train_pca,y_train)

metrics_model_pca9 = model_metrics(X_test_pca,y_test,logistic_regression_pca)


```

Avaliando as métricas

In [24]:

```
y_pred_test1 = logistic_regression.predict(X_test)
CM1 = confusion_matrix(y_pred = y_pred_test1, y_true = y_test)

y_pred_test2 = logistic_regression_2.predict(X_test_2)
CM2 = confusion_matrix(y_pred = y_pred_test2, y_true = y_test)

pca = PCA(13)
pca_X = pca.fit(X)
X_pca = pd.DataFrame(pca_X.transform(X))
X_train_pca, X_test_pca, y_train, y_test = train_test_split(X_pca, y, test_size = 0.15,
logistic_regression_pca = LogisticRegression(n_jobs=-1, random_state=15)
logistic_regression_pca.fit(X_train_pca,y_train)

y_pred_test_pca13 = logistic_regression_pca.predict(X_test_pca)
CM13 = confusion_matrix(y_pred = y_pred_test_pca13, y_true = y_test)

pca = PCA(9)
pca_X = pca.fit(X)
X_pca = pd.DataFrame(pca_X.transform(X))
X_train_pca, X_test_pca, y_train, y_test = train_test_split(X_pca, y, test_size = 0.15,
logistic_regression_pca = LogisticRegression(n_jobs=-1, random_state=15)
logistic_regression_pca.fit(X_train_pca,y_train)

y_pred_test_pca9 = logistic_regression_pca.predict(X_test_pca)
CM9 = confusion_matrix(y_pred = y_pred_test_pca9, y_true = y_test)
```

In [25]:

```
f, axes = plt.subplots(2, 2, figsize=(20, 15), facecolor='white')
f.suptitle(' Matrizes de Confusão')

plt.figure(figsize=(1, 1))
ax1 = sns.heatmap(CM1,annot=True, cmap="Blues", fmt="d",
            xticklabels = ['Bom pagador', 'Mal pagador'],
            yticklabels = ['Bom pagador', 'Mal pagador'], ax=axes[0,0])

plt.figure(figsize=(1, 1))
ax2 = sns.heatmap(CM2,annot=True, cmap="Blues", fmt="d",
            xticklabels = ['Bom pagador', 'Mal pagador'],
            yticklabels = ['Bom pagador', 'Mal pagador'], ax=axes[0,1])

plt.figure(figsize=(1, 1))
ax3 = sns.heatmap(CM13,annot=True, cmap="Blues", fmt="d",
            xticklabels = ['Bom pagador', 'Mal pagador'],
            yticklabels = ['Bom pagador', 'Mal pagador'], ax=axes[1,0])

plt.figure(figsize=(1, 1))
ax4 = sns.heatmap(CM9,annot=True, cmap="Blues", fmt="d",
            xticklabels = ['Bom pagador', 'Mal pagador'],
            yticklabels = ['Bom pagador', 'Mal pagador'], ax=axes[1,1]);

```

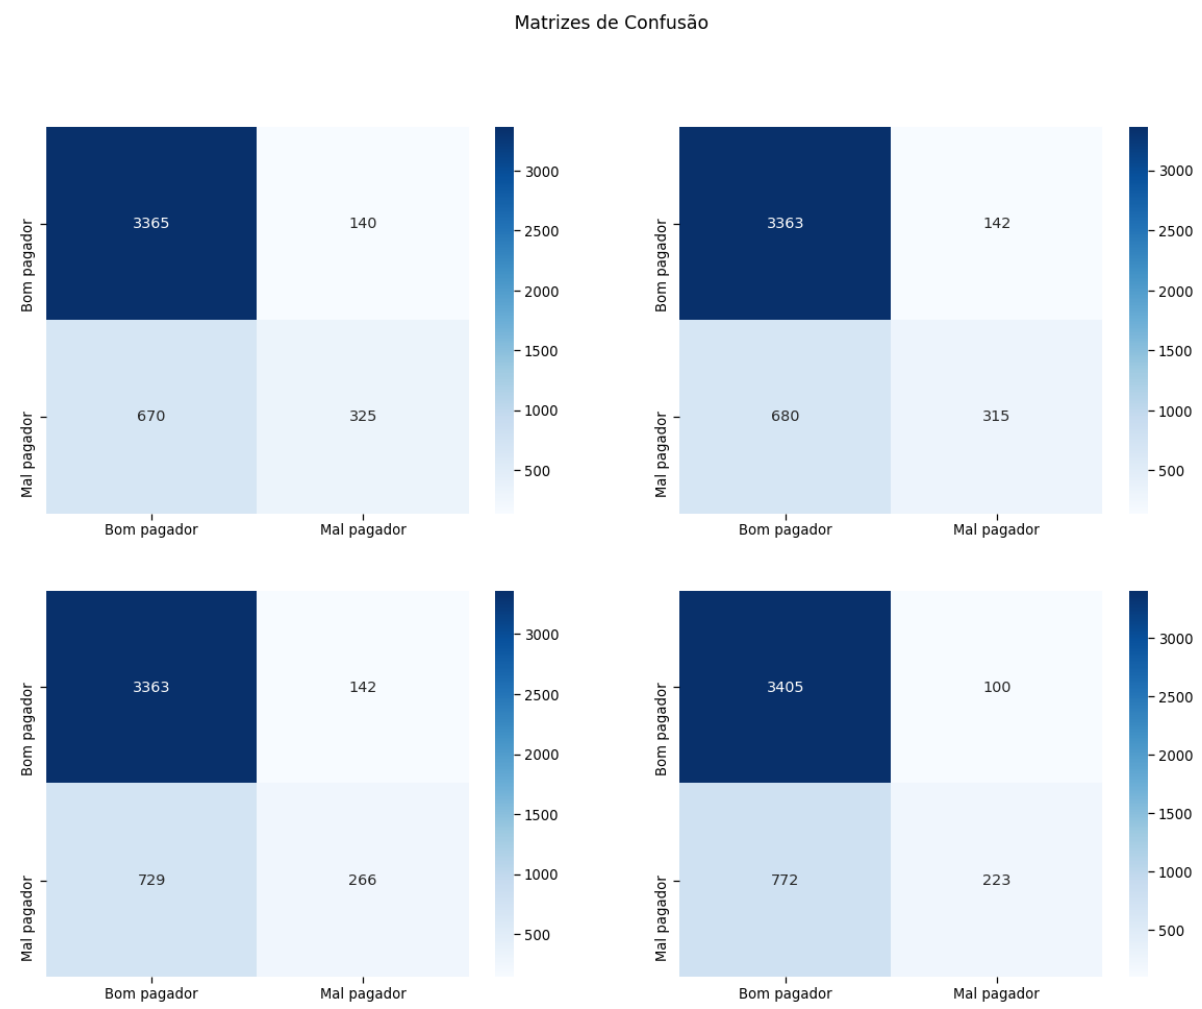

```
<Figure size 72x72 with 0 Axes>
```

```
<Figure size 72x72 with 0 Axes>
```

```
<Figure size 72x72 with 0 Axes>
```

```
<Figure size 72x72 with 0 Axes>
```

In [26]:

```
1 metrics_model_2['model'] = 'model_2'
2 metrics_model_1['model'] = 'model_1'
3 metrics_model_pca['model'] = 'pca_13'
4 metrics_model_pca9['model'] = 'pca_9'
5 g = sns.catplot(data=pd.concat([metrics_model_1,metrics_model_2,metrics_model_pca,metri
```

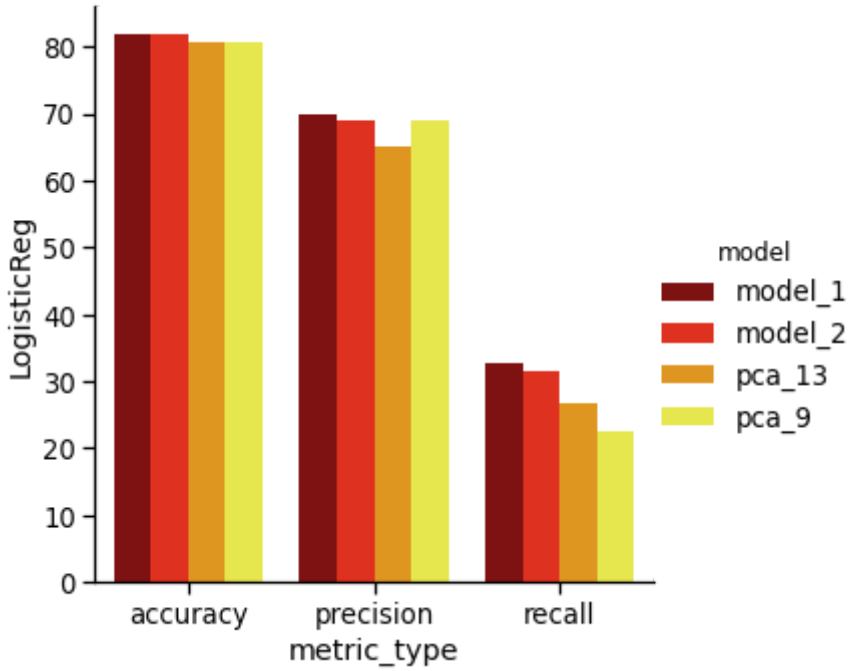

Simulação

Função para receber dados externos

In [27]:

```python
def cadastro(cliente):

    #transformando o dict em série
    cliente = pd.Series(cliente)

    #dimensionando e normalizando
    info = cliente.values.reshape(1, -1)
    info = robust_scaler.transform(info)

    #como "info" e "X" são np array, vamos converter para dataframe
    info = pd.DataFrame(info, columns = default.drop("default", axis = 1).columns)

    #vamos concatenar essa linha aos dados originais
    novos_dados = pd.concat([info, X])

    return novos_dados
```

In [28]:

```python
def teste(novos_dados):

    #Definindo a dimensão do dado

    pca_function = PCA(9)

    try:
        pca_function_teste = pca_function.fit(novos_dados)
        dado_reduzido = pd.DataFrame(pca_function_teste.transform(novos_dados))


        prob = logistic_regression_pca.predict_proba(dado_reduzido[:1])[0][1]

        if prob >= 0.25:
            print(f"Esse vai dever\n\nScore: {round(100/prob, 3)}\nProb de dever: {rou
        else:
            print(f"Camarada que paga!\n\nScore: {round(100/prob, 3)}\nProb de dever: {

    except ValueError:
        print("Dado com dimensão grande demais")

```

In [29]:

```python
yuri = OrderedDict([("limit_bal", 4000), ("age", 30), ("pay_0", -5), ("pay_2", 0),("pay

cliente = cadastro(yuri)
teste(cliente)
```

```
Camarada que paga!

Score: 1494.585
Prob de dever: 6.69%
```

In [30]:

```
luiz = OrderedDict([("limit_bal", 1000), ("age", 19), ("pay_0", 0), ("pay_2", 0),("pay_

cliente2 = cadastro(luiz)
teste(cliente2)
```

```
Camarada que paga!

Score: 640.948
Prob de dever: 15.6%
```

In [31]:

```
gustavo = OrderedDict([("limit_bal", 30000), ("age", 19), ("pay_0", 3), ("pay_2", 4),('

cliente3 = cadastro(gustavo)
teste(cliente3)
```

```
Esse vai dever

Score: 102.178
Prob de dever: 97.87%
```

In [32]:

```
ari = OrderedDict([("limit_bal", 3000), ("age", 19), ("pay_0", 0), ("pay_2", -1),("pay_


cliente4 = cadastro(ari)
teste(cliente4)
```

```
Camarada que paga!

Score: 1908.339
Prob de dever: 5.24%
```

Referencias e dados

Logistic Regression - THE MATH YOU SHOULD KNOW https://www.youtube.com/watch?v=YMJtsYIp4kg (https://www.youtube.com/watch?v=YMJtsYIp4kg)

https://www.kaggle.com/selener/prediction-of-credit-card-default/notebook (https://www.kaggle.com/selener/prediction-of-credit-card-default/notebook)

Logistic Regression Details Pt1: Coefficients https://www.youtube.com/watch?v=BfKanl1aSG0 (https://www.youtube.com/watch?v=BfKanl1aSG0)

Logistic Regression Details Pt 2: Maximum Likelihood https://www.youtube.com/watch?v=BfKanl1aSG0&t=383s (https://www.youtube.com/watch?v=BfKanl1aSG0&t=383s)

Making Predictions with Data and Python : Predicting Credit Card Default | packtpub.com https://www.youtube.com/watch?v=zUqa6KcwRhs&app=desktop (https://www.youtube.com/watch?v=zUqa6KcwRhs&app=desktop)